
بسم الله الرحمن الرحيم

دانشگاه اصفهان

دانشکده ریاضی و آمار

گروه علوم کامپیوتر

گزارش پیشرفت پروژه کارشناسی رشته علوم کامپیوتر

# مطالعه و ارزیابی روش‌های بهینه‌سازی k-means با تمرکز بر الگوریتم GLKM

استاد راهنما:

سرکار خانم دکتر نجمه حسینی منجزی

دانشجو:

داوود نصرتی امیرآبادی

مرداد ۱۴۰۵

# چکیده

این گزارش، فعالیت‌های انجام‌شده در مرحله‌ی نخست پروژه‌ی کارشناسی با موضوع خوشه‌بندی k-means و الگوریتم Greedy Local K-Means (GLKM) را مستند می‌نماید. ابتدا سیر تاریخی و الگوریتمی چند روش اصلی، از الگوریتم مک‌کوئین و کوانتیزاسیون لوید تا روش هارتیگان–وونگ و مقداردهی اولیه‌ی k-means++، مطالعه و مقایسه شده است. سپس ساختار GLKM و دو ایده‌ی توسعه‌ای بررسی شده‌اند: برآورد خودکار تعداد خوشه‌ها با نمودار elbow، و استفاده از یک افراز اولیه‌ی حاصل از k-means++ پیش از اجرای GLKM. برای ایده‌ی نخست، ابزار اجرای خودکار روی چند مقدار $k$ و تخمین نقطه‌ی آرنج پیاده‌سازی شد. آزمایش‌ها نشان دادند که در داده‌ی Gisette منحنی هزینه تقریباً خطی بود و تخمین elbow با ساختار برچسب‌های واقعی سازگار نبود. در ایده‌ی دوم نیز، کیفیت خوشه‌بندی در آزمایش انجام‌شده کاهش یافت. بنابراین این مرحله هنوز به یک بهبود عمومی برای GLKM منجر نشده است، اما عملکرد دو مسیر پیشنهادی را روشن و بستر آزمایش‌های بعدی را آماده کرده است.

کلیدواژه‌ها: خوشه‌بندی، k-means، GLKM، روش elbow، k-means++

# فهرست مطالب


فهرست تصاویر ت

فهرست جداول ث

مقدمه ج

۱ از کوانتیزاسیون تا **k-means** ۱

۱.۱ تابع هدف پایه . . . . . ۱

۲.۱ روش مک‌کوئین . . . . . ۱

۱.۲.۱ الگوریتم برخط . . . . . ۲

۲.۲.۱ نسخه‌ی دسته‌ای و تغییر تعداد مراکز . . . . . ۲

۳.۱ لوید و کوانتیزاسیون کمترین مربعات . . . . . ۳

۴.۱ خروجی تعاملی فصل . . . . . ۳

۲ بهبودهای کلاسیک و انتخاب مرکز ۴

۱.۲ مقداردهی اولیه‌ی k-means++ . . . . . ۴

۲.۲ سایر مسیرهای مطالعه‌شده . . . . . ۵

۱.۲.۲ روش global k-means . . . . . ۵

۲.۲.۲ X-means . . . . . ۵

۳ الگوریتم **GLKM** ۶

۱.۳ انگیزه و بازنویسی تابع هدف . . . . . ۶

۲.۳ ماتریس فاصله . . . . . ۶
۳.۳ شتاب‌دهی‌ها . . . . . ۶
۴.۳ ایده‌ها برای توسعه این پروژه . . . . . ۷

۴ بررسی روش آرنج برای تخمین تعداد خوشه‌ها ۸
۱.۴ آزمایش نخست: داده‌ی D1 . . . . . ۸
۲.۴ آزمایش دوم: داده‌ی Gisette . . . . . ۸
۳.۴ جمع‌بندی آزمایش . . . . . ۹

۵ افراز اولیه‌ی **k-means++** برای **GLKM** ۱۰
۱.۵ صورت دقیق ایده . . . . . ۱۰
۲.۵ نتایج مقدماتی روی Gisette . . . . . ۱۰
۳.۵ نتیجه‌گیری کلی . . . . . ۱۱

منابع و مآخذ ۱۲

# فهرست تصاویر

۱.۱ نمونه‌ی مستطیل در مقاله‌ی مک‌کوئین؛ یک حد ممکن در سمت چپ و افراز کم‌هزینه‌تر در سمت راست. . . . . ۲

۱.۴ دو شکست روش آرنج . . . . . ۹

۱.۵ زمان کل و کیفیت برای افرازهای اولیه‌ی مختلف روی Gisette. . . . . ۱۱

# فهرست جداول


۱.۱ ترجمه‌ی اصطلاحات لوید به زبان خوشه‌بندی . . . . . ۳

۱.۴ هزینه‌ی GLKM روی Gisette برای مقادیر مختلف $k$ . . . . . ۸

۱.۵ اثر اندازه‌ی افراز اولیه؛ عبارت $10k$ یعنی آغاز از ۲۰ خوشه . . . . . ۱۰

# مقدمه

هدف پروژه‌ی کارشناسی حاضر، مطالعه‌ی دقیق الگوریتم Greedy Local K-Means یا به اختصار GLKM [۹] و بررسی امکان بهبود آن است. این الگوریتم با بازنویسی تابع هدف k-means به‌صورت مجموع فاصله‌های زوجی و با استفاده از یک ماتریس فاصله‌ی تنک، از ادغام حریصانه‌ی خوشه‌ها استفاده می‌کند. در نقطه‌ی فعلی پروژه هنوز یک تغییر عمومی و دارای برتری برای GLKM به دست نیامده است. فعالیت‌های انجام‌شده در سه محور قرار می‌گیرند. محور نخست، مطالعه‌ی منابع تاریخی و الگوریتمی مهم شامل کارهای مک‌کوئین، لوید، هارتیگان—وونگ و k-means++ است. محور دوم، پیاده‌سازی اجرای GLKM برای بازه‌ای از مقادیر $k$ و تولید نمودار eblow است. محور سوم، پیاده‌سازی ایده‌ی استفاده از افراز اولیه‌ی k-means++ برای کاهش تعداد خوشه‌های آغازین GLKM است.

برای ملموس‌تر شدن تفاوت الگوریتم‌ها، دو صفحه‌ی وب مستقل و تعاملی نیز به کمک هوش مصنوعی ChatGPT ساخته شد: یکی مقایسه‌ی گام‌به‌گام روش مک‌کوئین با روش لوید، و دیگری مقایسه‌ی Hartigan–Wong با لوید. مسیر این خروجی‌ها در پوشه‌ی interactive پروژه ثبت شده است.

ساختار گزارش چنین است: فصل نخست مبانی اولیه را توضیح می‌دهد؛ فصل دوم به روش‌های پس از آن می‌پردازد؛ فصل سوم GLKM را تشریح می‌کند و فصل‌های چهارم و پنجم دو آزمایش و نتایج آن‌ها را گزارش می‌کنند.

# فصل ۱

# از کوانتیزاسیون تا k-means

## ۱.۱ تابع هدف پایه

برای مجموعه‌داده‌ی $\mathcal{X} = \{x_1, \dots, x_n\} \subset \mathbb{R}^d$ و افراز $\mathcal{S} = \{S_1, \dots, S_k\}$، تابع هدف رایج k-means برابر است با

$$\Phi(\mathcal{S}) = \sum_{i=1}^{k} \sum_{x \in S_i} \|x - \mu_i\|_2^2, \qquad \mu_i = \frac{1}{|S_i|} \sum_{x \in S_i} x. \tag{۱.۱}$$

دو تصمیم اصلی الگوریتم عبارت‌اند از انتساب هر نقطه به یک خوشه و محاسبه‌ی نماینده‌ی آن خوشه. برای فاصله، مربع فاصله‌ی اقلیدسی و برای انتخاب نماینده‌ی یک خوشه، میانگین مختصات نقاط آن در نظر گرفته است.

## ۲.۱ روش مک‌کوئین

مقاله‌ی مک‌کوئین در سال ۱۹۶۷ اصطلاح k-means را رواج داد [۱]، هرچند خود مقاله تصریح می‌کند که پیش‌تر فرایندی از این نوع به‌کار برده شده بود. فرمولبندی مک‌کوئین جمعیتی است: داده از توزیع احتمال $p$ می‌آید و برای افراز $S_1, \dots, S_k$، میانگین شرطی خوشه‌ی $i$ به‌صورت

$$u_i = \frac{\int_{S_i} z \, dp(z)}{p(S_i)} \tag{۲.۱}$$

تعریف می‌شود. واژه‌ی «شرطی» به شرط $z \in S_i$ اشاره دارد. استفاده از انتگرال در این مقاله و استفاده از دو جمع در رابطه‌ی ۱.۱ تفاوتی بنیادی نیست اما نکته‌ی جالب توجهی به نظر می‌رسد.

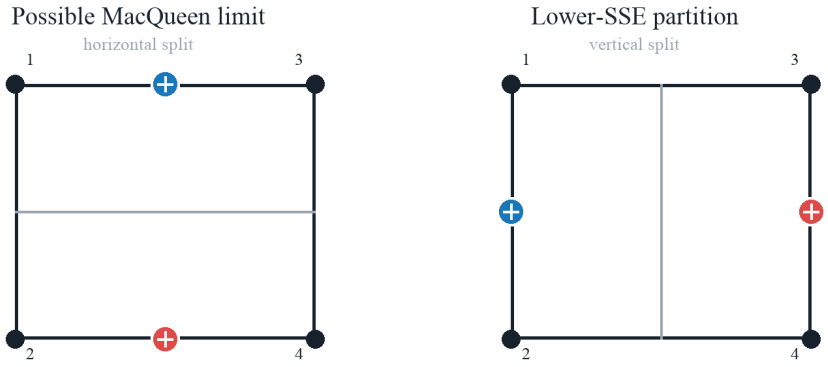
### ۱.۲.۱ الگوریتم برخط

در الگوریتم اصلی، $k$ مشاهده‌ی نخست به‌عنوان مراکز اولیه انتخاب می‌شوند و وزن هر مرکز برابر یک قرار می‌گیرد. این مقداردهی اولیه را نباید کاملاً غیرتصادفی دانست و نتیجه به ترتیب ورود داده‌ها وابسته است. مشاهده‌ی جدید $z_{n+k}$ به نزدیک‌ترین مرکز نسبت داده می‌شود. در حالت تساوی فاصله، مرکز با شماره‌ی کوچک‌تر انتخاب می‌شود. اگر نقطه به خوشه‌ی $i$ افزوده شود،

$$x_i^{n+1} = \frac{w_i^n x_i^n + z_{n+k}}{w_i^n + 1}, \qquad w_i^{n+1} = w_i^n + 1, \tag{۳.۱}$$

و سایر مراکز و وزن‌ها ثابت می‌مانند. این همان به‌روزرسانی میانگین است ولی به ذخیره‌ی تمام نقاط پیشین نیاز ندارد.

در انتهای مقاله، یک مثال مستطیل‌شکل به عنوان نمونه آورده شده تا نمایانگر حالتی باشد که این روش به انتخاب یک خوشه‌بندی نامناسب (البته به صورت محلی بهین) میپردازد. نمونه‌ی چهار رأس یک مستطیل کمی کشیده، این محدودیت را روشن می‌کند. برای $k = 2$، الگوریتم ممکن است به افراز افقی شکل ۱.۱ برسد، درحالی‌که افراز عمودی هزینه‌ی کم‌تری دارد.




شکل ۱.۱: نمونه‌ی مستطیل در مقاله‌ی مک‌کوئین؛ یک حد ممکن در سمت چپ و افراز کم‌هزینه‌تر در سمت راست.

### ۱.۲.۲ نسخه‌ی دسته‌ای و تغییر تعداد مراکز

بخش ۳/۶ مقاله یک روش دسته‌ای را توصیف می‌کند: از یک افراز آغاز می‌شود، میانگین همه‌ی خوشه‌ها هم‌زمان محاسبه می‌شود، تمام نقاط دوباره به نزدیک‌ترین میانگین نسبت داده می‌شوند و این دو گام تکرار می‌شوند. برخلاف نسخه‌ی برخط، در اینجا کل مجموعه‌داده در هر دور بازبینی می‌شود. روی داده‌ی متناهی، واریانس درون‌خوشه‌ای کاهش می‌یابد و فرایند پس از تعداد متناهی گام متوقف می‌شود.

مک‌کوئین همچنین دو آستانه‌ی $C$ و $R$ را برای تغییر تعداد مراکز پیشنهاد می‌کند: دو مرکز با فاصله‌ی کمتر از $C$ ادغام می‌شوند و نقطه‌ای با فاصله‌ی بیش از $R$ از نزدیک‌ترین مرکز، خود به مرکز جدید تبدیل می‌شود.

## ۳.۱ لوید و کوانتیزاسیون کمترین مربعات

مقاله‌ی لوید [۲] ابتدا در سال ۱۹۵۷ در آزمایشگاه بل نوشته شد و در سال ۱۹۸۲ انتشار یافت. هدف، نمایش نمونه‌های ولتاژ با تعداد محدودی مقدار بازسازی‌شده و کمینه کردنِ متوسطِ نویز کوانتیزاسیون بود.

جدول ۱.۱: ترجمه‌ی اصطلاحات لوید به زبان خوشه‌بندی

| لوید | k-means |
|---|---|
| نمونه‌های ولتاژ | نقاط داده |
| بازه‌ها یا زیرمجموعه‌های کوانتیزاسیون | خوشه‌ها |
| مقادیر کوانتیزه $q_a$ | مراکز یا میانگین‌های خوشه |
| نویز کوانتیزاسیون | مجموع مربعات خطا |
| کمینه کردن متوسط نویز | کمینه کردن فاصله‌ی مربع‌شده‌ی مورد انتظار |

## ۴.۱ خروجی تعاملی فصل

فایل interactive/macqueen-vs-lloyd.html دو روش را روی یک داده‌ی مشترک کنار هم نمایش می‌دهد. در سمت مک‌کوئین، هر گام فقط یک نقطه و یک میانگین را تغییر می‌دهد؛ در سمت لوید، انتساب برای همه‌ی نقاط صورت گرفته و سپس همه‌ی مراکز به‌صورت دسته‌ای به‌روز می‌شوند.

# فصل ۲

# بهبودهای کلاسیک و انتخاب مرکز

## ۱.۲ مقداردهی اولیه‌ی k-means++

آرتور و واسیلیویتسکی نشان دادند که انتخاب دقیق‌تر مراکز اولیه می‌تواند کیفیت مورد انتظار k-means را کنترل کند [۴]. الگوریتم k-means++ چنین است:

۱. مرکز نخست به‌صورت یکنواخت از نقاط داده انتخاب می‌شود.

۲. اگر $D(x)$ فاصله‌ی نقطه‌ی $x$ تا نزدیک‌ترین مرکز انتخاب‌شده باشد، مرکز بعدی با احتمال

$$P(x) = \frac{D(x)^2}{\sum_{x' \in \mathcal{X}} D(x')^2} \tag{۱.۲}$$

انتخاب می‌شود.

۳. گام دوم تا انتخاب $k$ مرکز تکرار و سپس الگوریتم معمول لوید اجرا می‌شود.

این نمونه‌گیری «وزن‌دهی $D^2$» نام دارد. قضیه‌ی اصلی مقاله بیان می‌کند

$$\mathbb{E}[\Phi] \le 8(\ln k + 2)\Phi_{\mathrm{OPT}}. \tag{۲.۲}$$

بنابراین روش در بدترین حالت $O(\log k)$ـرقابتی است و برای نمونه‌های خوب می‌تواند کران ثابت داشته باشد. روش پیشینِ استروفسکی و همکاران، کران ثابت را تحت شرط

$$\frac{\Phi_{\mathrm{OPT},k}}{\Phi_{\mathrm{OPT},k-1}} \le \varepsilon^2 \tag{۳.۲}$$

به دست می‌داد؛ یعنی جواب $k$ـخوشه‌ای باید به‌طور محسوسی بهتر از جواب $(k-1)$ـخوشه‌ای باشد.

لم ۱.۲ (هویت مرکز ثقل). برای مجموعه‌ی متناهی $S$، مرکز ثقل $c(S)$ و هر نقطه‌ی $z$ داریم

$$\sum_{x\in S}\|x-z\|^2=\sum_{x\in S}\|x-c(S)\|^2+|S|\|c(S)-z\|^2. \tag{۴.۲}$$

تفسیر رابطه‌ی ۴.۲ این است که هزینه‌ی انتخاب هر نماینده‌ی دلخواه برابر است با هزینه‌ی (فاصله‌ی) نقاط نسبت به مرکز ثقل واقعی، به‌علاوه‌ی جریمه‌ی دور بودن آن نماینده از مرکز ثقل که در تعداد نقاط ضرب می‌شود.

## ۲.۲ سایر مسیرهای مطالعه‌شده

### ۱.۲.۲ روش global k-means

روش global k-means [۵] مراکز را یکی‌یکی اضافه می‌کند. برای افزایش تعداد خوشه‌ها از $k-1$ به $k$، هر نقطه‌ی داده یک‌بار به‌عنوان مرکز جدید در کنار جواب قبلی آزمایش و لوید اجرا می‌شود؛ بهترین جواب نگه داشته می‌شود. این جست‌وجوی قطعی حساسیت به مقداردهی اولیه را کاهش می‌دهد، اما اجرای مکرر آن پرهزینه است. نسخه‌ی سریع مقاله با یک کران کاهش خطا، نامزدها را محدود می‌کند.

### ۲.۲.۲ X-means

X-means [۶] از یک کران پایین برای $k$ آغاز می‌کند و خوشه‌ها را به‌صورت محلی برای شکستن به دو بخش نامزد می‌کند. این فرایند تا کران بالای $k$ ادامه می‌یابد. مزیت اصلی آن جست‌وجوی هم‌زمان ساختار و تعداد خوشه‌هاست، ولی نتیجه به مدل آماری و بازه‌ی مجاز $k$ وابسته است.

# فصل ۳

# الگوریتم GLKM

## ۱.۳ انگیزه و بازنویسی تابع هدف

مقاله‌ی اصلی پروژه، GLKM، روشی حریصانه برای بهینه‌سازی k-means ارائه می‌کند [۹]. زوجی بودن تابع جریمه

$$\sum_{x\in S}\|x-\mu_S\|^2=\frac{1}{2|S|}\sum_{x,y\in S}\|x-y\|^2 \qquad (۱.۳)$$

اجازه می‌دهد هزینه‌ی هر خوشه بدون نمایش صریح مرکز آن و با استفاده از فاصله‌های زوجی محاسبه شود. GLKM از $n$ خوشه‌ی تک‌عضوی شروع می‌کند و در هر مرحله زوجی را ادغام می‌کند که کمترین افزایش تابع هدف را داشته باشد؛ این روند تا رسیدن به تعداد خوشه‌ی درخواستی $k$ ادامه می‌یابد.

## ۲.۳ ماتریس فاصله

نگهداری همه‌ی $n^2$ فاصله برای داده‌ی بزرگ مناسب نیست. مقاله یک گراف $K$ـ‌نزدیک‌ترین همسایه می‌سازد. برای یال‌های موجود، فاصله‌ی مربع‌شده‌ی واقعی و برای زوج‌های فاقد یال مقدار $\gamma$ در نظر گرفته می‌شود؛ $\gamma$ بر مبنای بزرگ‌ترین فاصله‌ی موجود در گراف تنظیم می‌شود. در نتیجه، هدف محاسبه‌شده دقیقاً تابع هدف اقلیدسی کامل نیست، بلکه تقریب آن است.

## ۳.۳ شتاب‌دهی‌ها

سه ایده‌ی اصلی برای کاهش هزینه‌ی جست‌وجوی ادغام‌ها به‌کار رفته است:

۱. به‌روزرسانی جبری هزینه‌ی ادغام با نگهداری آمار خوشه‌ها، به‌جای محاسبه‌ی دوباره‌ی تمام فاصله‌ها؛

۲. محدود کردن زوج‌های نامزد به همسایگی گراف:؛

۳. نگهداری نامزدهای ادغام در ساختاری مرتب برای دسترسی سریع به کمترین افزایش.

## ۴.۳ ایده‌ها برای توسعه این پروژه

دو پرسش از مطالعه‌ی روش حاصل شد:

۱. آیا می‌توان با اجرای GLKM روی چند مقدار $k$ و نمودار elbow نیاز به دریافت $k$ از کاربر را ااز بین برد؟

۲. آیا می‌توان به‌جای آغاز از $n$ خوشه‌ی تک‌عضوی، یک افراز اولیه‌ی کوچک‌تر ساخت تا تعداد ادغام‌ها و زمان اجرای هسته‌ی GLKM کاهش یابد؟

فصل‌های بعدی پیاده‌سازی و ارزیابی مقدماتی این دو پرسش را گزارش می‌کنند.

# فصل ۴

# بررسی روش آرنج برای تخمین تعداد خوشه‌ها

## ۱.۴ آزمایش نخست: داده‌ی D1

آزمایش برای $k = 2, \ldots, 10$ و گراف ۱۲ـ نزدیک‌ترین همسایه اجرا شد و هزینه برابر 100936.0647 باقی ماند. در نتیجه هیچ منحنی آرنج معناداری ساخته نشد.

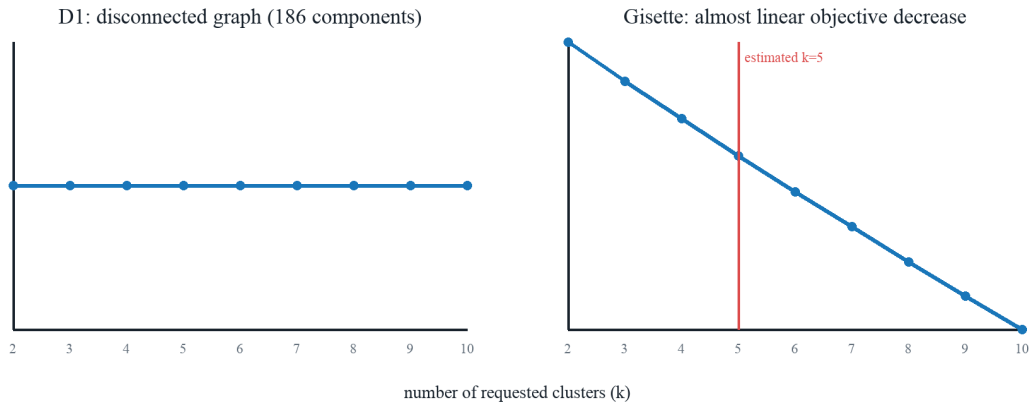
## ۲.۴ آزمایش دوم: داده‌ی Gisette

برای داده‌ی Gisette با گراف ۸۰ـ نزدیک‌ترین همسایه، الگوریتم به همه‌ی مقادیر درخواستی رسید. نتایج تابع هدف در جدول ۱.۴ آمده است.

جدول ۱.۴: هزینه‌ی GLKM روی Gisette برای مقادیر مختلف $k$

| $k$ | ۲ | ۳ | ۴ | ۵ | ۶ | ۷ | ۸ | ۹ | ۱۰ |
|---|---|---|---|---|---|---|---|---|---|
| $\Phi/10^7$ | 2.586 | 2.580 | 2.574 | 2.568 | 2.563 | 2.557 | 2.552 | 2.546 | 2.541 |

روش فاصله از وتر $k = 5$ را انتخاب کرد؛ بااین‌حال کاهش هزینه تقریباً خطی است. همچنین معیارهای ACC و NMI در $k = 2$ بهتر بودند. بنابراین $k = 5$ بیشتر محصول حساسیت هندسی روش eblow است.




شکل ۱.۴: دو شکست روش آرنج

## ۳.۴ جمع‌بندی آزمایش

روش آرنج در شکل فعلی جایگزین مطمئنی برای ورودی $k$ نیست.هرچند بر اساس یافته‌های فعلی می‌توان در آینده مسیر توسعه بهتری را در پیش گرفت.

# فصل ۵

# افراز اولیه‌ی k-means++ برای GLKM

## ۱.۵ صورت دقیق ایده

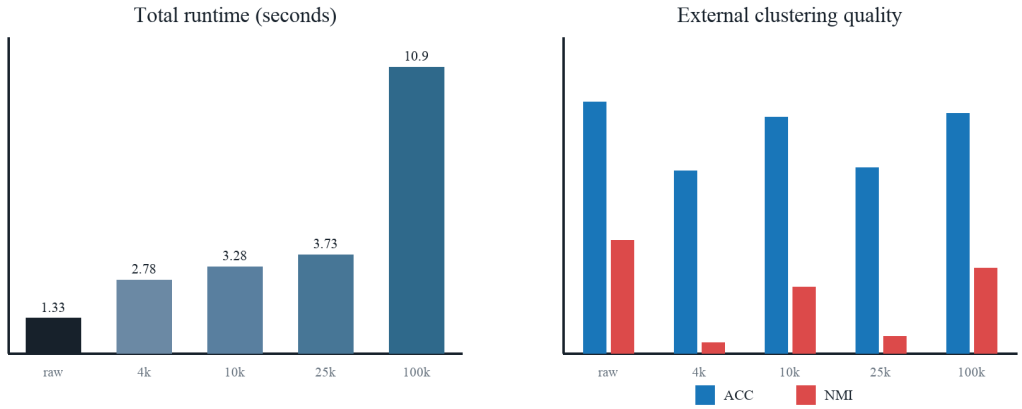
در نسخه‌ی اصلی GLKM هر نقطه یک خوشه‌ی تک‌عضوی است؛ بنابراین برای رسیدن به $k$ خوشه تقریباً $n-k$ ادغام لازم است. ایده‌ی آزمایش‌شده آن بود که ابتدا $m=\alpha k$ خوشه بسازیم و سپس GLKM را از این افراز آغاز کنیم تا فقط $m-k$ ادغام انجام شود.

## ۲.۵ نتایج مقدماتی روی Gisette

آزمایش نخست با $k=2$ و گراف ۸۰ـنزدیک‌ترین همسایه انجام شد. جدول ۱.۵ زمان کل و معیارهای بیرونی را نشان می‌دهد.

جدول ۱.۵: اثر اندازه‌ی افراز اولیه؛ عبارت $10k$ یعنی آغاز از ۲۰ خوشه

| آغاز | زمان کل (ثانیه) | هزینه‌ی تقریبی ($10^7$) | ACC | NMI |
|---|---|---|---|---|
| تک‌عضوی (اصلی) | 1.33 | 2.586 | 0.795 | 0.358 |
| $4k$ | 2.78 | 2.562 | 0.577 | 0.033 |
| $10k$ | 3.28 | 2.561 | 0.748 | 0.210 |
| $25k$ | 3.73 | 2.561 | 0.588 | 0.054 |
| $100k$ | 10.87 | 2.563 | 0.760 | 0.269 |




شکل ۱.۵: زمان کل و کیفیت برای افرازهای اولیه‌ی مختلف روی Gisette.

افراز اولیه تعداد ادغام‌های هسته را کاهش می‌دهد، اما هزینه‌ی اجرای KMeans مقدماتی باعث شد زمان کل در همه‌ی حالت‌ها از روش اصلی بیشتر شود. هزینه‌ی تقریبی داخلی کمی کاهش یافت، ولی ACC و NMI بدتر

## ۳.۵ نتیجه‌گیری کلی

دستاورد این مرحله بیش از آن‌که یک الگوریتم بهتر باشد، تبدیل دو ایده‌ی اولیه به فرضیه‌های قابل‌آزمون و مشخص کردن حالت‌های شکست آن‌هاست. روش elbow قابل اتکا نیست. افراز اولیه‌ی فعلی نیز در آزمایش انجام‌شده زمان کل و کیفیت بیرونی را بهبود نداد. در مقابل، مطالعه‌ی منابع تاریخی و جدید، ایجاد ابزارهای تکرارپذیر، بهبود زمان و ساخت صفحات تعاملی، پایه‌ی روشنی برای مرحله‌ی بعد پروژه فراهم کرده است.

# منابع و مآخذ


[۱] J. MacQueen, “Some Methods for Classification and Analysis of Multivariate Observations,” in Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, vol. 1, pp. 281–297, 1967.

[۲] S. P. Lloyd, “Least Squares Quantization in PCM,” IEEE Transactions on Information Theory, vol. 28, no. 2, pp. 129–137, 1982.

[۳] J. A. Hartigan and M. A. Wong, “Algorithm AS 136: A K-Means Clustering Algorithm,” Journal of the Royal Statistical Society, Series C (Applied Statistics), vol. 28, no. 1, pp. 100–108, 1979.

[۴] D. Arthur and S. Vassilvitskii, “k-means++: The Advantages of Careful Seeding,” in Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA), pp. 1027–1035, 2007.

[۵] A. Likas, N. Vlassis, and J. J. Verbeek, “The Global k-means Clustering Algorithm,” Pattern Recognition, vol. 36, no. 2, pp. 451–461, 2003.

[۶] D. Pelleg and A. Moore, “X-means: Extending K-means with Efficient Estimation of the Number of Clusters,” in Proceedings of the 17th International Conference on Machine Learning, pp. 727–734, 2000.

[۷] G. Frahling and C. Sohler, “A Fast k-Means Implementation Using Coresets,” International Journal of Computational Geometry & Applications, vol. 18, no. 6, pp. 605–625, 2008.

[۸] D. Choo, C. Grunau, J. Portmann, and V. Rozhon, “k-means++: Few More Steps Yield Constant Approximation,” in Proceedings of the 37th International Conference on Machine Learning, pp. 1909–1917, 2020.

[۹] Y. Yuan, L. Zhao, S. Pei, and F. Nie, “Efficient Greedy Optimization Method for k-means,” Pattern Recognition, vol. 171, p. 112140, 2026.